МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) Кафедра МО ЭВМ

КУРСОВАЯ РАБОТА

по дисциплине «Введение в нереляционные базы данных» Тема: Инструмент сбора данных о научных публикаций

	Хотяков Е.П. Лапина А.А.
Студенты гр. 9383	Лихашва А.Д.
Преподаватель	Заславский М.М.

Санкт-Петербург

ЗАДАНИЕ НА КУРСОВУЮ РАБОТУ

Студенты: Хотяков Е.П., Лапина А.А., Лихашва А.Д.	
Группа: 9383.	
Tема проекта: Инструмент сбора данных о научных пуб	ликаций.
Исходные данные: Необходимо реализовать веб-инструме	ент для импорта
данных из источников по сложным запросам (фио / органи	изации / года /
издания), для аггрегации и генерации отчетов, экспорта	а. СУБД —
MongoDB. Набор данных/API - Google Scholar / elibrary / С	ORCID / Publons
API.	
Содержание пояснительной записки:	
Введение, Качественные требования к решению, Сценари	и использования,
Модель данных, Нереляционная модель данных, Аналог моде	ели данных для SQI
СУБД, Сравнение моделей, Разработанное приложение, Выг	воды, Приложения
Литературы.	
Предполагаемый объем пояснительной записки:	
Не менее 10 страниц.	
Дата выдачи задания: 10.10.2022	
Дата сдачи реферата: 21.12.2022	
Дата защиты реферата: 21.12.2022	
	Хотяков Е.П.
Студенты	Лапина А.А. Лихашва А.Д.
Преподаватель	Заславский М.М.

АННОТАЦИЯ

В рамках данного курса предполагалось разработать какое-либо приложение в команде на одну из поставленных тем. Была выбрана тема создания инструмента сбора данных о научных публикациях с использованием MongoDB, так как мы хотели получить опыт работы с данной СУБД, а также принести пользу университету, потому что наше приложение может облегчить поиск научных статей для преподавателей. Найти исходный код и всю дополнительную информацию можно по ссылке: https://github.com/moevm/nosql2h22-publications.

SUMMARY

As part of this course, it was supposed to develop an application in a team on one of the topics set. The topic of creating a data collection tool for scientific publications using MongoDB was chosen, as we wanted to gain experience with this DBMS, as well as benefit the university, because our application can facilitate the search for scientific articles for teachers. You can find the source code and all additional information at the link: https://github.com/moevm/nosql2h22-publications.

СОДЕРЖАНИЕ

1.	Введение	6
2.	Качественные требования к решению	6
3.	Сценарии использования	6
4.	Модель данных	10
4.1	Нереляционная модель данных	10
4.2.	Аналог модели данных для SQL СУБД	14
4.3.	Сравнение моделей	18
5.	Разработанное приложение	18
6.	Выводы	19
7.	Приложения	20
8.	Литературы	23

1. Введение

В настоящее время занятие научной деятельностью становится все более популярным, но к сожалению, получение структурированной информации по какому либо критерию, например, по автору становится довольно трудоемкой задачей, так как необходимо посетить множество сайтов для получения информации, где она может быть представлена не в самом удобном виде. Поэтому выбранная тема обладает высокой актуальностью, так как с помощью разрабатываемого инструмента исследователи смогут находить научные публикации по определенным критериям.

Цель работы – разработать инструмент сбора данных о научных публикаций.

Было решено разработать веб-приложение, которое позволит хранить в электронном виде данные о научных публикациях, при этом позволяющее удобно с ними взаимодействовать.

2. Качественные требования к решению

Требуется разработать инструмент сбора данных о научных публикаций с использованием СУБД — MongoDB для удобного поиска информации о публикациях с возможностью импорта/экспорта данных.

3. Сценарии использования

Макеты UI

Полную схему макета можно увидеть здесь:

https://www.figma.com/file/c3mDE8NkMgXGYxpv3288Cq/%D0%9F %D0%BE%D0%B8%D1%81%D0%BA-%D0%BD %D0%B0%D1%83%D1%87%D0%BD%D1%8B%D1%85-%D0%BF

%D1%83%D0%B1%D0%BB%D0%B8%D0%BA %D0%B0%D1%86%D0%B8%D0%B9?node-id=0%3A1

1. Экран Начальный экран:

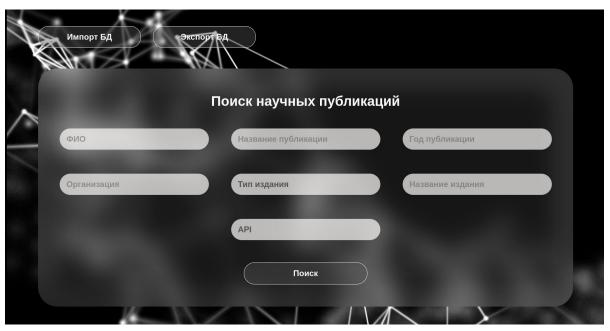


Рисунок 1 — Начальный экран

2. Экран при получении данных при поиске по параметрам (в данном случае автор):



Рисунок 2 - Экран при получении данных при поиске по параметрам

3. Экран при отсутствии данных при поиске по параметрам (в данном случае автор):

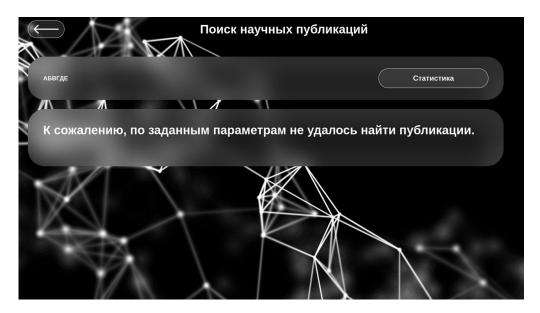


Рисунок 3 - Экран при отсутствии данных при поиске по параметрам

Описание сценариев использования

Действующее лицо: Пользователь.

Основной сценарий:

<u>Цель:</u> Поиск научных публикаций

- 1. Пользователь заходит на начальный экран, где отображены 4 поля: «ФИО», «Организация», «Год публикации», «Название публикации», где пользователь заполняет их (обязательно должно быть заполнено хотя бы 1 поле).
- 2. Пользователь нажимает на кнопку «Поиск» .
- 3. Пользователь видит полученные данные:
- Если они нашлись, они отображаются. Пользователь может экспортировать найденные данные.
- Если при поиске не нашлось подходящих публикаций, пользователь увидит сообщение.

- 4. Пользователь хочет получить новые данные, возвращается на начальный экран, изменяет содержимое полей на желаемое.
- 5. Переход на шаг 2.

Альтернативный сценарий 1:

<u>Цель:</u> Импорт БД

- 1. Пользователь заходит на начальный экран.
- 2. Нажимает кнопку «Импорт БД».

Альтернативный сценарий 2:

<u>Цель:</u> Экспорт БД

- 1. Пользователь заходит на начальный экран.
- 2. Нажимает кнопку «Экспорт БД».

Альтернативный сценарий 3:

<u>Цель:</u> Просмотр с подробным описанием публикации

- 1. Пользователь получает список публикаций на экране 2.
- 2. Нажимает на строку с нужной публикацией.
- 3. Открывается экран 4 с описанием публикации.

Альтернативный сценарий 4:

<u>Цель:</u> Получение статистики

- 1. Пользователь получает список публикаций на экране 2.
- 2. Нажимает на кнопку "Статистика".

- 3. Открывается экран 5.
- 4. Пользователь выбирает тип издания для статистики.
- 5. Получение статистики.

4. Модель данных

4.1 Нереляционная модели данных

Графическое представление

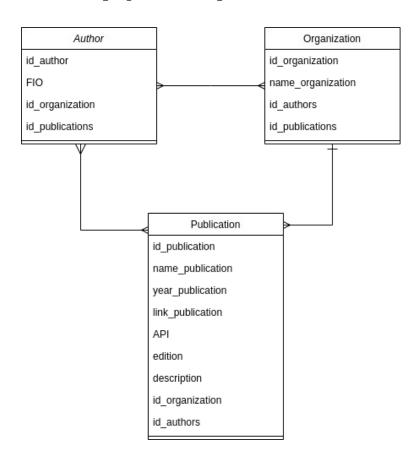


Рисунок 4 — Графическое представление нереляционной модели

Описание назначений коллекций, типов данных и сущностей

Всего в проекте необходимо 3 сущности - Author - автор, Organization - организация и Publication - публикация. (В MongoDB латинские буквы и символы кодируются 1 байтом, а кириллические буквы – 2 байтами).

Ниже представлено описание коллекций: Database

```
author:
                               // коллекция, содержащая информацию об авторе
                                    (итого 84 байта)
{
    id author: ObjectId,
                                      // идентификатор автора (12 байт)
    FIO: String,
                                  // ФИО автора (до 30 символов или 60 байт)
    id organization: ObjectId,
                                        // идентификатор организации (12 байт)
    id publications: [ObjectId, ..., ObjectId] // публикации (от 12 байт)
}
organization:
                                  // коллекция, содержащая информацию об
организации (итого 76 байта)
{
    id organization: ObjectId,
                                        // идентификатор организации (12 байт)
    name_organization: String,
                                         // название организации (до 20 символов или 40
байт)
    id_authors: [ObjectId, ..., ObjectId]
                                       // авторы (от 12 байт)
    id publications: [ObjectId, ..., ObjectId] // публикации (от 12 байт)
}
publication:
                             // коллекция, содержащая информацию о публикации
(итого 445 байта)
{
    id publication: ObjectId,
                                     // идентификатор публикации (12 байт)
    name publication: String,
                                      // название публикации (до 20 символов или 40
байт)
    year publication: 64-Bit Integer,
                                        // год публикации (4 байта)
    link publication: String,
                                    // ссылка на публикацию (до 50 символов или 50
байт)
    API: String,
                                // АРІ (до 15 символов или 15 байт)
    edition: String,
                                  // издание (до 30 символов или 60 байт)
    description: String
                                   // краткое описание публикации (до 130 символов
или 260 байт)
    id organization: ObjectId,
                                        // идентификатор организации (12 байт)
    id authors: [ObjectId, ..., ObjectId]
                                         // авторы (от 12 байт)
}
```

Пример данных

```
<u>Автор:</u>
{
    id_author: ObjectId("1111a1e112df7f8644c2cea2"),
    FIO: "Лапина Анастасия Андреевна",
    id organization: ObjectId("2222a1e112df7f8644c2cea2"),
    id publications: [ObjectId("3333a1e112df7f8644c2cea2"),
ObjectId("aaaaa1e112df7f8644c2cea2")]
}
Организация:
    id_organization: ObjectId("2222a1e112df7f8644c2cea2"),
    name organization: "ЛЭТИ",
    id_authors: [ObjectId("1111a1e112df7f8644c2cea2")]
    id_publications: [ObjectId("3333a1e112df7f8644c2cea2"),
ObjectId("aaaaa1e112df7f8644c2cea2")]
}
}
Публикация:
{
    id_publication: ObjectId("3333a1e112df7f8644c2cea2"),
    name publication: "Имя публикации",
    year publication: 2022,
    link_publication: "https:/etu.ru",
    API: "Google Scholar",
    edition: "Научное издание номер 1",
    description: "В публикации ...",
    id_organization: ObjectId("2222a1e112df7f8644c2cea2"),
    id authors: [ObjectId("1111a1e112df7f8644c2cea2")]
}
```

Оценка удельного объема информации, хранимой в модели (сколько потребуется памяти, чтобы сохранить объекты, как объем зависит от количества объектов)

Будем считать, что у нас Ха- авторов, Хо - организаций и Хр - публикаций. Следовательно, объем информации можно найти так: 84 * Ха + 76 * Хо + 445 * Хр, Хо и Хр можно считать словарями, и значит, их размеры берем за константу, тогда получаем оценку удельного объема информации: 605*Ха

Избыточность модели

Избыточными полями в нашей бд являются: id_author, id_organization, id_publication. Тогда суммарный объем избыточных данных равен 36, а чистых 569*Ха Следовательно, избыточность модели равна: (605/569)*Ха ~ 1,06

Направление роста модели

Рассматривая модель данных и полученные результаты, можно сделать вывод о том, что модель растёт с линейной скоростью.

Запросы к модели, с помощью которых реализуются сценарии использования

•Поиск автора

let FIO_ = "Иванов Иван Иванович";

db.author.find({FIO: FIO });

•Поиск организации

let organization = "ЛЭТИ";

db.organization.find({name organization: organization});

•Поиск публикации

let publication = "Какое-то название";

db.publication.find({name publication: publication});

4.2 Аналог модели данных для SQL СУБД - характеризуется аналогично нереляционной

Графическое представление

Разработана аналогичная схема реляционной базы данных:

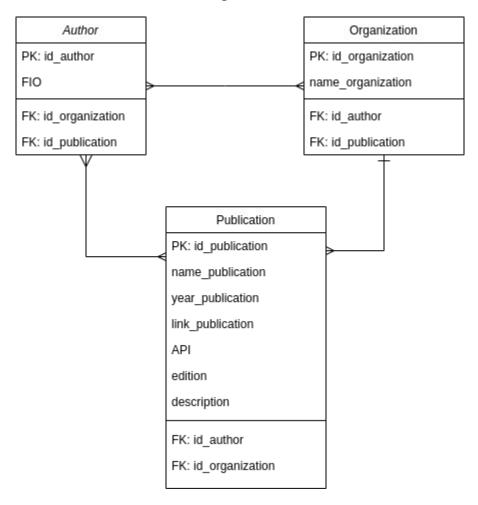


Рисунок 5 — Графическое представление реляционной модели

Описание назначений коллекций, типов данных и сущностей

Всего в проекте необходимо 3 сущности - Author - автор, Organization - организация и Publication - публикация.

Ниже представлено описание коллекций: Будем использовать Unicode, то есть символы кодируются 2 байтами Database:

```
author:
                        // коллекция, содержащая информацию об авторе (итого 96
байта)
{
    id author: ObjectId,
                              // идентификатор автора (12 байт)
    FIO: String,
                           // ФИО автора (до 30 символов или 60 байт)
    id organization: ObjectId,
                                // идентификатор организации (12 байт)
    id publication: ObjectId
                               // идентификатор публикации (12 байт)
}
organization:
                              // коллекция, содержащая информацию об организации
(итого 76 байта)
{
    id organization: ObjectId,
                                   // идентификатор организации (12 байт)
    name organization: String,
                                     // название организации (до 20 символов или 40
байт)
    id author: ObjectId,
                                  // идентификатор автора (12 байт)
                                   // идентификатор публикации (12 байт)
    id publication: ObjectId
}
publication:
                            // коллекция, содержащая информацию о публикации
(итого 530 байта)
{
    id_publication: ObjectId,
                                     // идентификатор публикации (12 байт)
    name_publication: String,
                                      // название публикации (до 20 символов или 40
байт)
    year_publication: 64-Bit Integer
                                        // год публикации (4 байта)
    link publication: String
                                    // ссылка на публикацию (до 50 символов или 100
байт)
    API: String
                                // АРІ (до 15 символов или 30 байт)
    edition: String
                                 // издание (до 30 символов или 60 байт)
    description: String
                                   // краткое описание публикации (до 130 символов
или 260 байт)
    id author: ObjectId,
                                    // идентификатор автора (12 байт)
    id organization: ObjectId
                                     // идентификатор организации (12 байт)
}
```

Пример данных

```
<u>Автор:</u>
{
    id author: ObjectId("1111a1e112df7f8644c2cea2"),
    FIO: "Лапина Анастасия Андреевна",
    id organization: ObjectId("2222a1e112df7f8644c2cea2"),
    id publication: ObjectId("3333a1e112df7f8644c2cea2")
}
Организация:
{
    id organization: ObjectId("2222a1e112df7f8644c2cea2"),
    name organization: "ЛЭТИ",
   id author: ObjectId("1111a1e112df7f8644c2cea2"),
   id publication: ObjectId("3333a1e112df7f8644c2cea2")
}
Публикация:
{
    id publication: ObjectId("3333a1e112df7f8644c2cea2"),
    name publication: "Имя публикации",
    year_publication: 2022,
    link publication: "https:/etu.ru",
    API: "Google Scholar",
    edition: "Научное издание номер 1",
    description: "В публикации ...",
    id author: ObjectId("1111a1e112df7f8644c2cea2"),
    id organization: ObjectId("2222a1e112df7f8644c2cea2")
}
```

Оценка удельного объема информации, хранимой в модели (сколько потребуется памяти, чтобы сохранить объекты, как объем зависит от количества объектов)

Будем считать, что у нас Ха- авторов, Хо - организаций и Хр - публикаций. Следовательно, объем информации можно найти так: 96 * Ха + 76 * Хо + 530 * Хр, Хо и Хр можно считать словарями, и значит, их размеры берем за константу, тогда получаем оценку удельного объема информации: 702*Ха

Избыточность модели

Избыточными полями в нашей бд являются: id_author, id_organization, id_publication. Тогда суммарный объем избыточных данных равен 36, а чистых 666*Ха Следовательно, избыточность модели равна: (702/666)*Ха ~ 1,05

Направление роста модели

Рассматривая модель данных и полученные результаты, можно сделать вывод о том, что модель растёт с линейной скоростью.

Запросы к модели, с помощью которых реализуются сценарии использования

•Поиск по автору

SELECT publication.publication_name, author.FIO, publication.year_publication, publication.edition, publication.API, publication.description FROM publication

JOIN publication on publication.id_publication = author.id_publication WHERE author.FIO = "Иванов Иван Иванович";

•Поиск по организации

SELECT publication.publication_name, author.FIO, publication.year_publication, publication.description
FROM publication

JOIN publication on publication.id_publication = author.id_publication

JOIN organization on organization.id_organization = publication.id_organization

WHERE organization.name organization = "ЛЭТИ";

•Поиск по публикациям

SELECT publication.publication_name, author.FIO, publication.year_publication, publication.description
FROM publication

JOIN publication on publication.id_publication = author.id_publication
WHERE publication.name publication = "Публикация номер 1";

4.3 Сравнение моделей

Сравнение реляционной и нереляционной моделей представлено в следующей таблице:

	NoSQL	SQL
Удельный объём информации	605 * Xa	702 * Xa
Избыточность	1.06	1.05
Количество коллекций	3	3

Анализируя данные, можно сделать вывод, что нереляционная база данных лучше подходит для данной задачи, нежели реляционная, так как удельный объем информации у нереляционной меньше, при этом показатель избыточности у нее незначительно больше, поэтому им можно пренебречь.

5. Разработанное приложение

Краткое описание

Инструмент сбора данных о научных публикациях реализован на языке программирования - JavaScript. С помощью данного приложения можно совершать поиск научных статей по различным критериям таким как: ФИО, название публикации, год публикации, организация, тип издания, название издания, количество цитат и index. В случае, если данные по заданному запросу не найдены, то об этом сообщается пользователю. В качестве СУБД использована MongoDB.

Схема экранов приложения и/или схема интерфейса командной строки

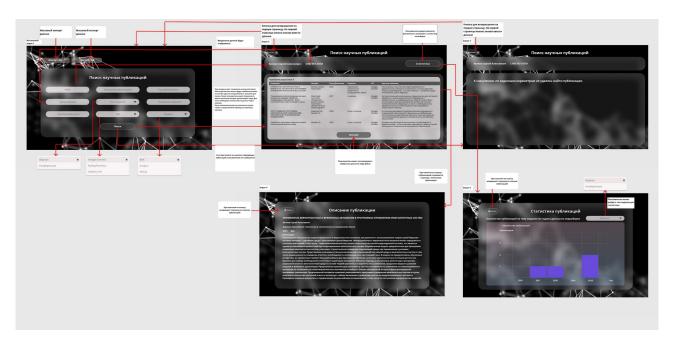


Рисунок 6 — Схема экранов приложения

Использованные технологии

БД: MongoDB,

Back-end, Front-end: JavaScript, HTML, CSS.

Ссылки на Приложение

Ссылка на github: https://github.com/moevm/nosql2h22-publications

6. Выводы

Достигнутые результаты

В ходе работы был разработан инструмент для поиска научных публикаций, который позволяет пользователям быстро и удобно находить информацию о научных публикациям по критериям: таким как: ФИО, название публикации, год публикации, организация, тип издания, название издания, количество цитат и index. Также создан докер-контейнер, который облегчает развертывание приложения.

Недостатки и пути для улучшения полученного решения

Пока приложение находится на стадии развития и не реализован раздел со статистикой.

Будущее развитие решения

В будущем планируем реализовать раздел с описанием статьи и сделать статистику.

7. Приложения

Документация по сборке и развертыванию приложения

- 1. Склонировать проект из репозитория (указан в ссылках на приложение)
- 2. Запустить докер-контейнер с помощью docker-compose build --no-cache
- 3. Открыть приложение в браузере по адресу http://localhost:3000

Инструкция для пользователя

Для получения информации о публикации:

1) Зайти на главный экран

- 2) Ввести необходимые параметры для поиска
- 3) Увидеть результат

Для импорта:

- 1) Зайти на главный экран
- 2) Нажать кнопку «Импорт БД»

Для экспорта:

- 1) Зайти на главный экран
- 2) Нажать кнопку «Экспорт БД»

Снимки экрана приложения

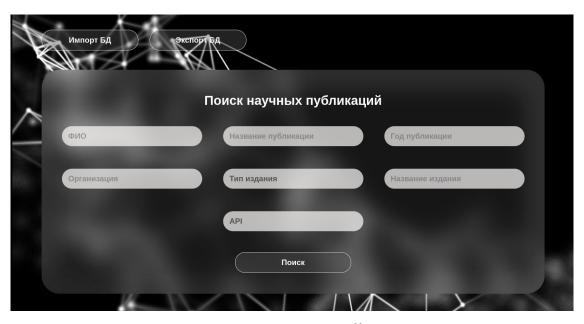


Рисунок 7 — Главный экран

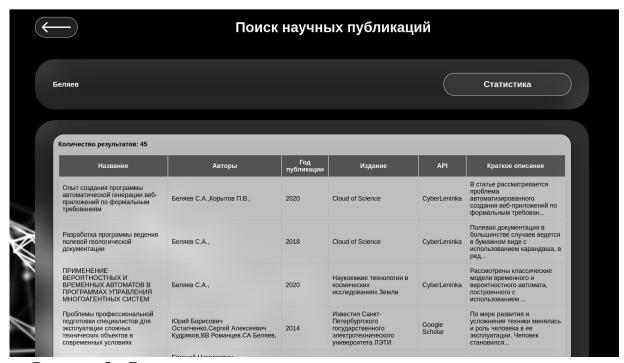


Рисунок 8 - Экран при получении данных при поиске по параметрам

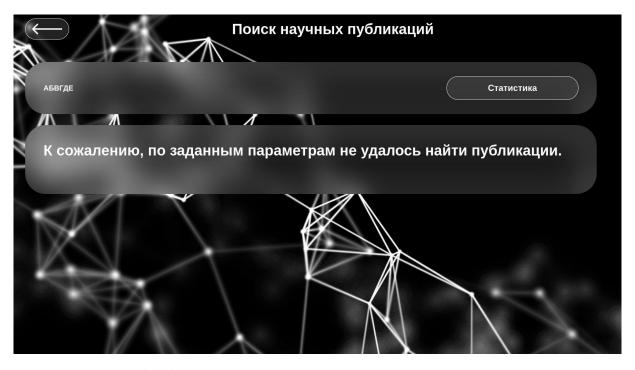


Рисунок 9 - Экран при отсутствии данных при поиске по параметрам

Поиск по критериям: ФИО, год, организация:

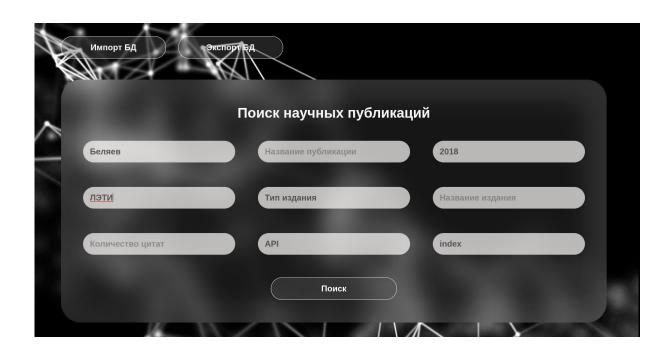


Рисунок 10 — Заполняем данные

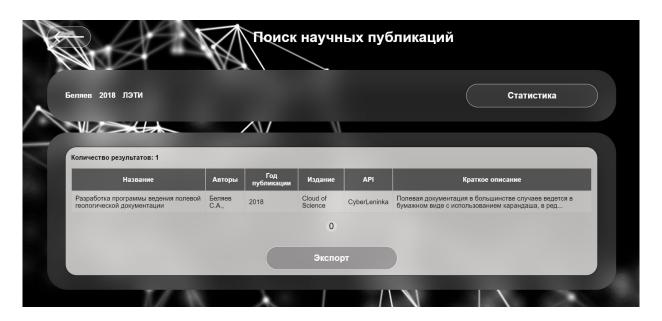


Рисунок 11 — Результат поиска

Поиск журналов в Google Scholar

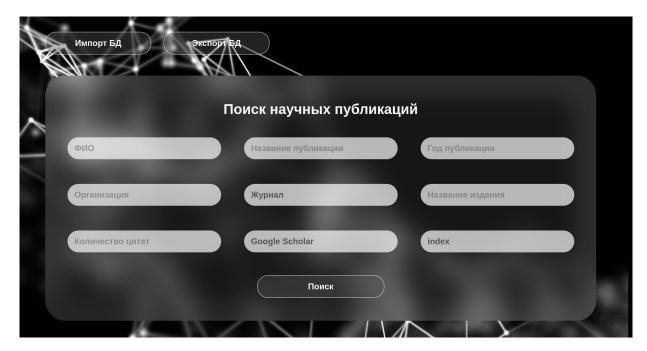


Рисунок 12 — Заполняем данные

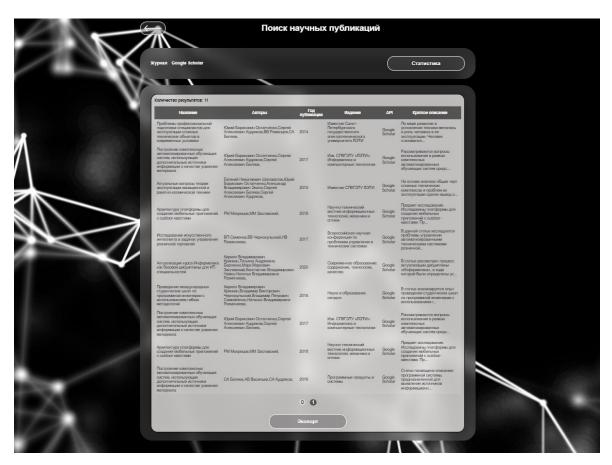


Рисунок 13 — Результат поиска

Импорт БД

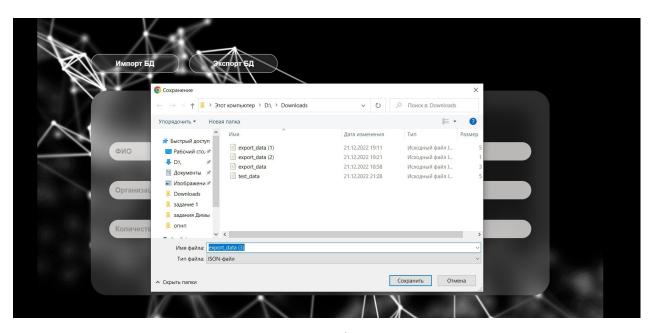


Рисунок 14 — Предложение выбрать названия файла при нажатии на «Импорт БД»

Экспорт БД

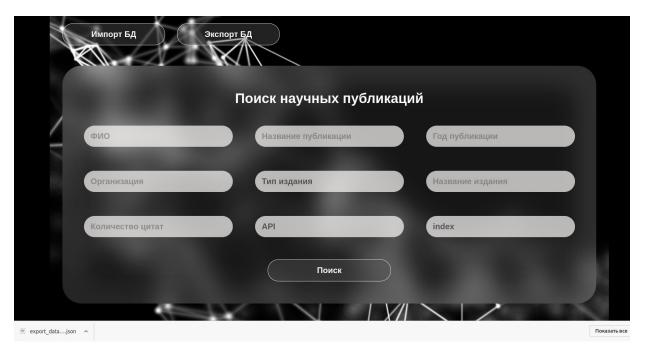


Рисунок 15 — Скачивается json при нажатии «Экспорт БД»

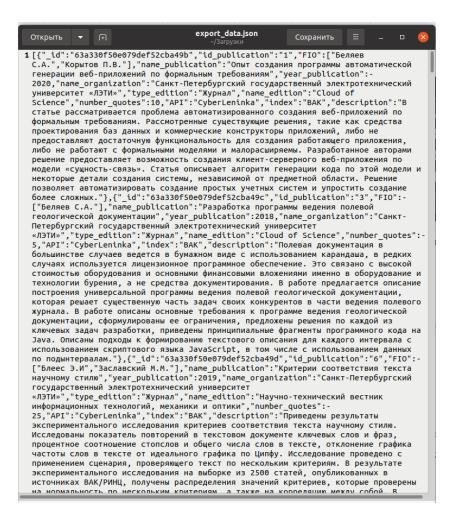


Рисунок 16 — Содержание экспортированного

8. Литература

1) Документация MongoDB: https://docs.mongodb.com/manual/

2) Документация к Docker: https://www.docker.com/